

TP547 - PRINCÍPIOS DE SIMULAÇÃO DE SISTEMAS DE COMUNICAÇÕES –

Trabalho Final - Parte 1

- Estudante: Daniel Quiteque.
- Matrícula: 823.
- Curso: Mestrado em Telecomunicações
- Professor: Prof. Dr. Samuel Mafra.
- Data: 05/05/2025

1. Artigo escolhido

Título: **Internet of Things Applications for Energy Management in Buildings Using Artificial Intelligence—A Case Study**

Referência: Energies 2025, 18, 1706. <https://doi.org/10.3390/en18071706>

2. Breve Introdução sobre o Artigo

O artigo explora, de forma aprofundada, como a convergência entre Internet das Coisas (IoT) e Inteligência Artificial (IA) pode reconfigurar o conceito de eficiência energética e a maneira como a energia é gerenciada em edifícios.

A abordagem não se limita apenas à automação básica. A proposta apresenta um ecossistema inteligente e adaptativo capaz de monitorar, prever e otimizar o consumo energético em tempo real, promovendo uma gestão mais eficiente, econômica e ambientalmente responsável. Dispositivos como sensores IoT coletam dados em tempo real sobre variáveis como temperatura, umidade, presença de pessoas e consumo energético. Esses dados são processados por algoritmos de IA capazes de prever padrões de consumo, identificar ineficiências e ajustar dinamicamente os sistemas de HVAC (*Heating, Ventilation, and Air Conditioning*), ou seja, Aquecimento, Ventilação e Ar Condicionado., iluminação e dispositivos elétricos de acordo com a demanda e condições externas. A arquitetura inteligente também possibilita a detecção precoce de falhas e anomalias, otimizando a operação e reduzindo o tempo de inatividade.

2. Tema e Metodologia

Os experimentos foram realizados em um edifício de 3 andares e 10 salas em cada apartamento. Estes cômodos estavam equipados com sensores IoT para monitorar em tempo real o consumo de energia, condições

ambientais (temperatura, umidade, CO₂), presença de pessoas, iluminação e sistemas HVAC (aquecimento, ventilação e ar-condicionado).

Os dados coletados passaram por etapas de filtragem, interpolação e normalização para remover ruídos e lacunas. Em seguida, foram extraídas características importantes, como padrões de consumo e conforto térmico. Os dados foram divididos em conjuntos de treino e teste, e usados para treinar modelos de IA capazes de prever consumo energético, detectar falhas e otimizar o uso de energia.

Para analisar os dados coletados, o estudo seguiu um processo em várias etapas:

1. **Coleta de Dados:** Os dados vieram de sensores IoT instalados no prédio, incluindo medidores de energia inteligentes e controladores HVAC.
2. **Pré-processamento:** Como os dados brutos frequentemente apresentam ruído, lacunas ou inconsistências, foram aplicadas técnicas de filtragem, interpolação e normalização.
3. **Extração de Características:** Foram extraídos parâmetros importantes como fator de potência, distorção harmônica e tendências de consumo energético.
4. **Rotulagem de Dados:** Quando necessário, os dados foram rotulados manualmente ou semi-automaticamente, para treinar os modelos de IA com base em padrões de uso e eventos energéticos.
5. **Treinamento e Validação de Modelos:** Os dados foram divididos entre conjuntos de treino e teste. Em seguida, modelos de aprendizado de máquina e redes neurais foram treinados para prever consumo, detectar anomalias e propor estratégias de otimização.

O sistema de controle foi baseado em um sistema de gestão de edifícios BMS (*Building Management System*) inteligente, que tomava decisões automáticas sobre iluminação, ventilação e climatização. Para fins de validação, também foi realizada uma simulação dos ambientes no ambiente virtual *Blynk IoT*, permitindo testar as soluções propostas.

Além dessas informações, o artigo também apresenta detalhadamente todos os sensores usados, seus fabricantes, protocolos de comunicação (ZigBee, LoRa, Wi-Fi, Bluetooth), e os dispositivos de borda utilizados para processamento local, como Raspberry Pi, NVIDIA Jetson e Intel NUC, e algoritmos como LSTM, CNN e DQN para previsão e controle.

3. Reprodução de Resultado

Foi reproduzido um gráfico de previsão de consumo energético com base em um modelo LSTM(*Long Short-Term Memory*) - Que é um tipo especial de rede neural recorrente (RNN) projetado para aprender padrões em sequências de dados ao longo do tempo,. O gráfico compara os valores reais e os previstos de consumo energético, validando a eficácia do modelo de IA para prever padrões de consumo.




Fig 1 -Gráfico 1: Previsão de Consumo com LSTM

Outros dois resultados que são importantes apresentar no Relatório, são os gráficos que apresentam os níveis de redução de consumo por categoria e o gráfico que mostra os resultados com a otimização, usando algoritmos de IA:




Fig.2 -Gráfico 2: Redução de Consumo por Categoria




Fig. 3 - Gráfico 3: Consumo Diário Antes vs. Depois da Otimização

4. Simulação de Monte Carlo

Utilizando variáveis aleatórias para temperatura, CO₂, umidade e ocupação, foi realizada uma simulação de Monte Carlo para prever o consumo energético.

A função de consumo considera pesos relativos para cada variável e um ruído normal, gerando um conjunto de dados sintéticos. A distribuição das variáveis e o consumo foram visualizados em gráficos e sumarizados com estatísticas descritivas.

Índice	Temperatura	Umidade	CO ₂	Ocupação	Consumo (kWh)
0	24.993428	63.993554	532.482173	8	76.558424
1	23.723471	59.246337	585.548133	6	78.105950
2	25.295377	50.596304	520.758008	14	80.543409
3	27.046060	43.530632	569.203847	1	80.881747
4	23.531693	56.982233	410.638533	19	75.468627

Figura 4 - Redução do consumo de energia em diferentes categorias

Já a figura 5, abaixo, como visto representa distribuição que como vista, está na forma gaussiana praticamente, a mesma exibe a redução de consumo de energia em diferentes categorias, como HVAC e Iluminação. Os dados apresentam as porcentagens de redução para cada categoria. Nestes gráficos são apresentadas as as porcentagens de redução de consumo de energia para as categorias HVAC (29.7%), Iluminação (23.4%), e o total geral (33.8%). Cada barra é colorida de maneira diferente para destacar as categorias.

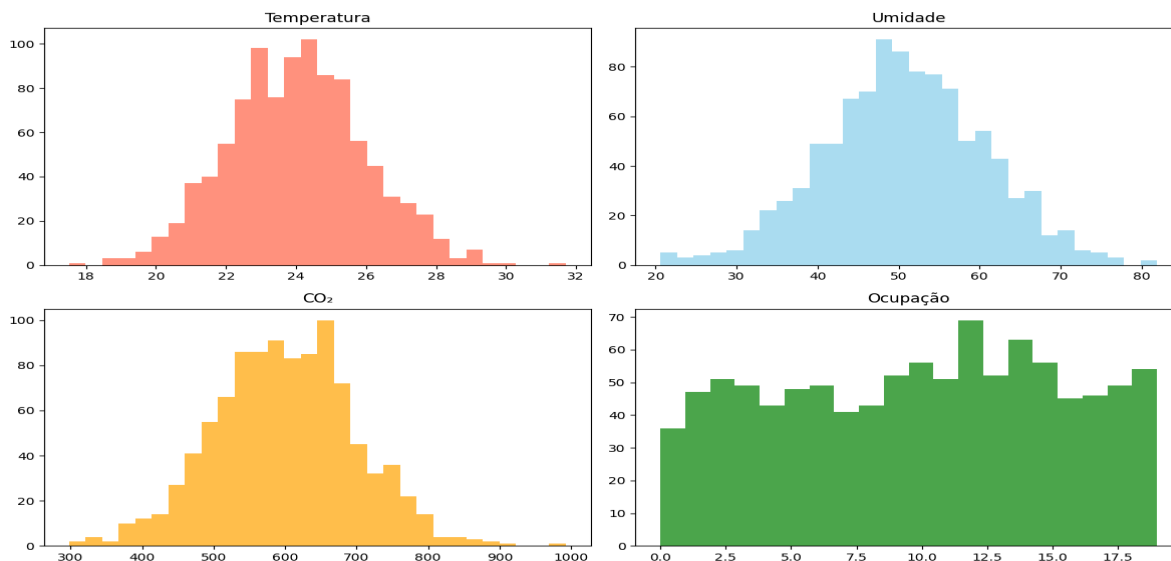


Figura 5 - Visualização das Distribuições

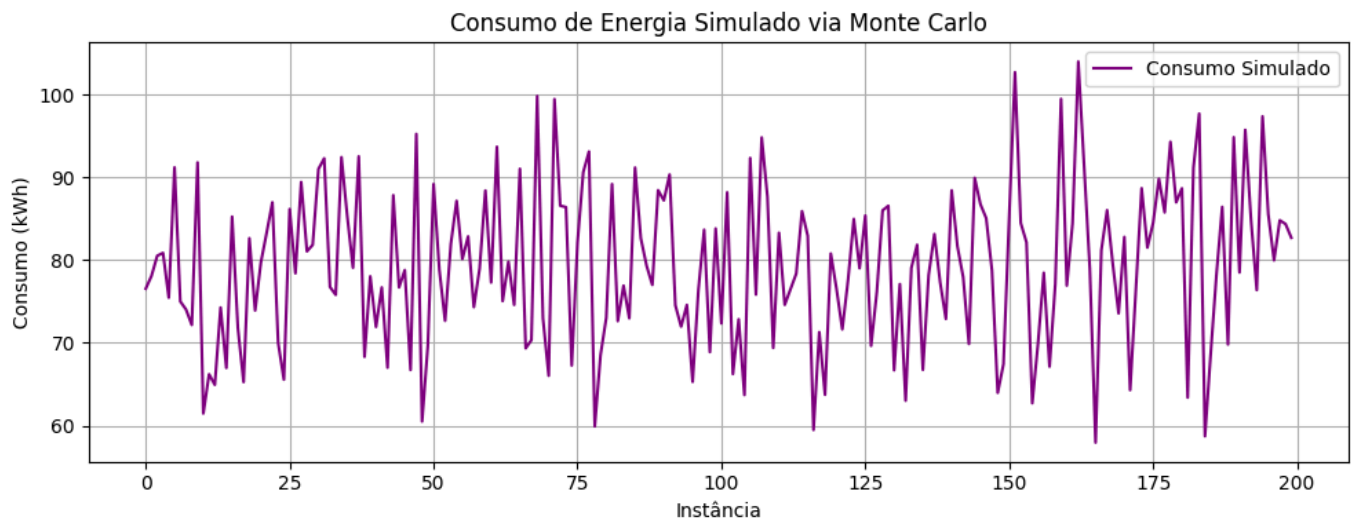


Figura 5 -Consumo de Energia Simulado via Monte Carlo

5. Conclusão

O uso de IA integrada a sensores IoT mostrou ser uma solução promissora para otimização do consumo energético em edificações. A simulação de Monte Carlo permitiu entender a sensibilidade do sistema a variações nas condições ambientais.

6. Referência

BUDZIANOWSKI, Wojciech M.; KWASNIK, Marcin; WRONA, Paulina.

Internet of Things Applications for Energy Management in Buildings Using Artificial Intelligence—A Case Study.

Energies, Basel, v. 18, n. 7, p. 1706, 2025.

Disponível em: <https://doi.org/10.3390/en18071706>.

Códigos:

🔗 graficos_energia_ai.ipynb

🔗 TP547-TF1_simulacao_monte_carlo_energia.ipynb

Todos os códigos utilizados estão disponíveis no GitHub:

[danielquiteque/TP547-Trabalho-Final-1: O presente repositório faz parte da disciplina de TP547- Da Disciplina de Princípios de Simulação, onde são apresentados os resultados do trabalho final parcial 01](#)