

Relatório resumido do artigo: "Internet of Things Applications for Energy Management in Buildings Using Artificial Intelligence" – A Case Study

Autores :W. M. Budzianowski, M. Kwasnik, and P. Wrona,

Estudante: **Daniel Quiteque**

Professor: **Prof. Doutor Samuel Beraldi Mafra**

05 de Maio de 2025



TRABALHO FINAL 1 – TP547 – PRINCÍPIOS DE SIMULAÇÃO

"Internet of Things Applications for Energy Management in Buildings Using Artificial Intelligence" – A Case Study

Autores :W. M. Budzianowski, M. Kwasnik, and

Estudante: **Daniel Quiteque**

Professor: **Prof. Doutor Samuel Beral**

05 de Maio de 2025

TRABALHO FINAL 1 – TP547 – PRINC

Article

Internet of Things Applications for Energy Management in Buildings Using Artificial Intelligence—A Case Study

Izabela Rojek ^{1,*}, Dariusz Mikołajewski ¹, Adam Mroziński ², Marek Macko ³, Tomasz Bednarek ¹ and Krzysztof Tyburek ¹

¹ Faculty of Computer Science, Kazimierz Wielki University, Chodkiewicza 30, 85-064 Bydgoszcz, Poland; dariusz.mikolajewski@ukw.edu.pl (D.M.); tomasz.bednarek@ukw.edu.pl (T.B.); krzysztof.tyburek@ukw.edu.pl (K.T.)

² Faculty of Mechanical Engineering, Bydgoszcz University of Science and Technology, Kaliskiego 7, 85-796 Bydgoszcz, Poland; adam.mrozinski@pbs.edu.pl

³ Faculty of Mechatronics, Kazimierz Wielki University, Chodkiewicza 30, 85-064 Bydgoszcz, Poland; mackomar@ukw.edu.pl

* Correspondence: izabela.rojek@ukw.edu.pl

Abstract: IoT applications for building energy management, enhanced by artificial intelligence (AI), have the potential to transform how energy is consumed, monitored, and optimized, especially in distributed energy systems. By using IoT sensors and smart meters, buildings can collect real-time data on energy usage patterns, occupancy, temperature, and lighting conditions. AI algorithms then analyze this data to identify inefficiencies, predict energy demand, and suggest or automate adjustments to optimize energy use. Integrating renewable energy sources, such as solar panels and wind turbines, into distributed systems uses IoT-based monitoring to ensure maximum efficiency in energy generation and use. These systems also enable dynamic energy pricing and load balancing, allowing buildings to participate in smart grids by storing or selling excess energy. AI-based predictive maintenance ensures that renewable energy systems, such as inverters and batteries, operate efficiently, minimizing downtime. The case studies show how IoT and AI are driving sustainable development by reducing energy consumption and carbon footprints in residential, commercial, and industrial buildings. Blockchain and IoT can further secure transactions and data in distributed systems, increasing trust, sustainability, and scalability. The combination of IoT, AI, and renewable energy sources is in line with global energy trends, promoting decentralized and greener energy systems. The case study highlights that adopting IoT and AI for energy management offers not only environmental benefits but also economic benefits, such as cost savings and energy independence. The best achieved accuracy was 0.8179 (RMSE 0.01). The overall effectiveness rating was 9/10; thus, AI-based IoT solutions are a feasible, cost-effective, and sustainable approach to office energy management.

Keywords: artificial intelligence; internet of things; optimization; energy saving; sustainability

1. Introduction

Effective energy management in buildings is becoming increasingly important in the context of global challenges related to climate change and increasing energy consumption. The construction sector is responsible for a significant portion of global energy consumption and greenhouse gas emissions, necessitating the implementation of modern technological solutions to minimize energy losses. The increase in energy prices and legal regulations



Academic Editor: Daniele D. Giusto

Received: 27 February 2025

Revised: 19 March 2025

Accepted: 25 March 2025

Published: 28 March 2025

Citation: Rojek, I.; Mikołajewski, D.; Mroziński, A.; Macko, M.; Bednarek, T.; Tyburek, K. Internet of Things Applications for Energy Management in Buildings Using Artificial Intelligence—A Case Study. *Energies* **2025**, *18*, 1706. <https://doi.org/10.3390/en18071706>

Copyright: © 2025 by the authors. Licensee MDPI, Basel, Switzerland. This article is an open access article distributed under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>).

Agenda

- Introdução
- Objetivo
- Metodologia
- Resultados
- Simulação de monte Carlo
- Geração de Variáveis aleatórias
- Conclusão
- Referência

Introdução

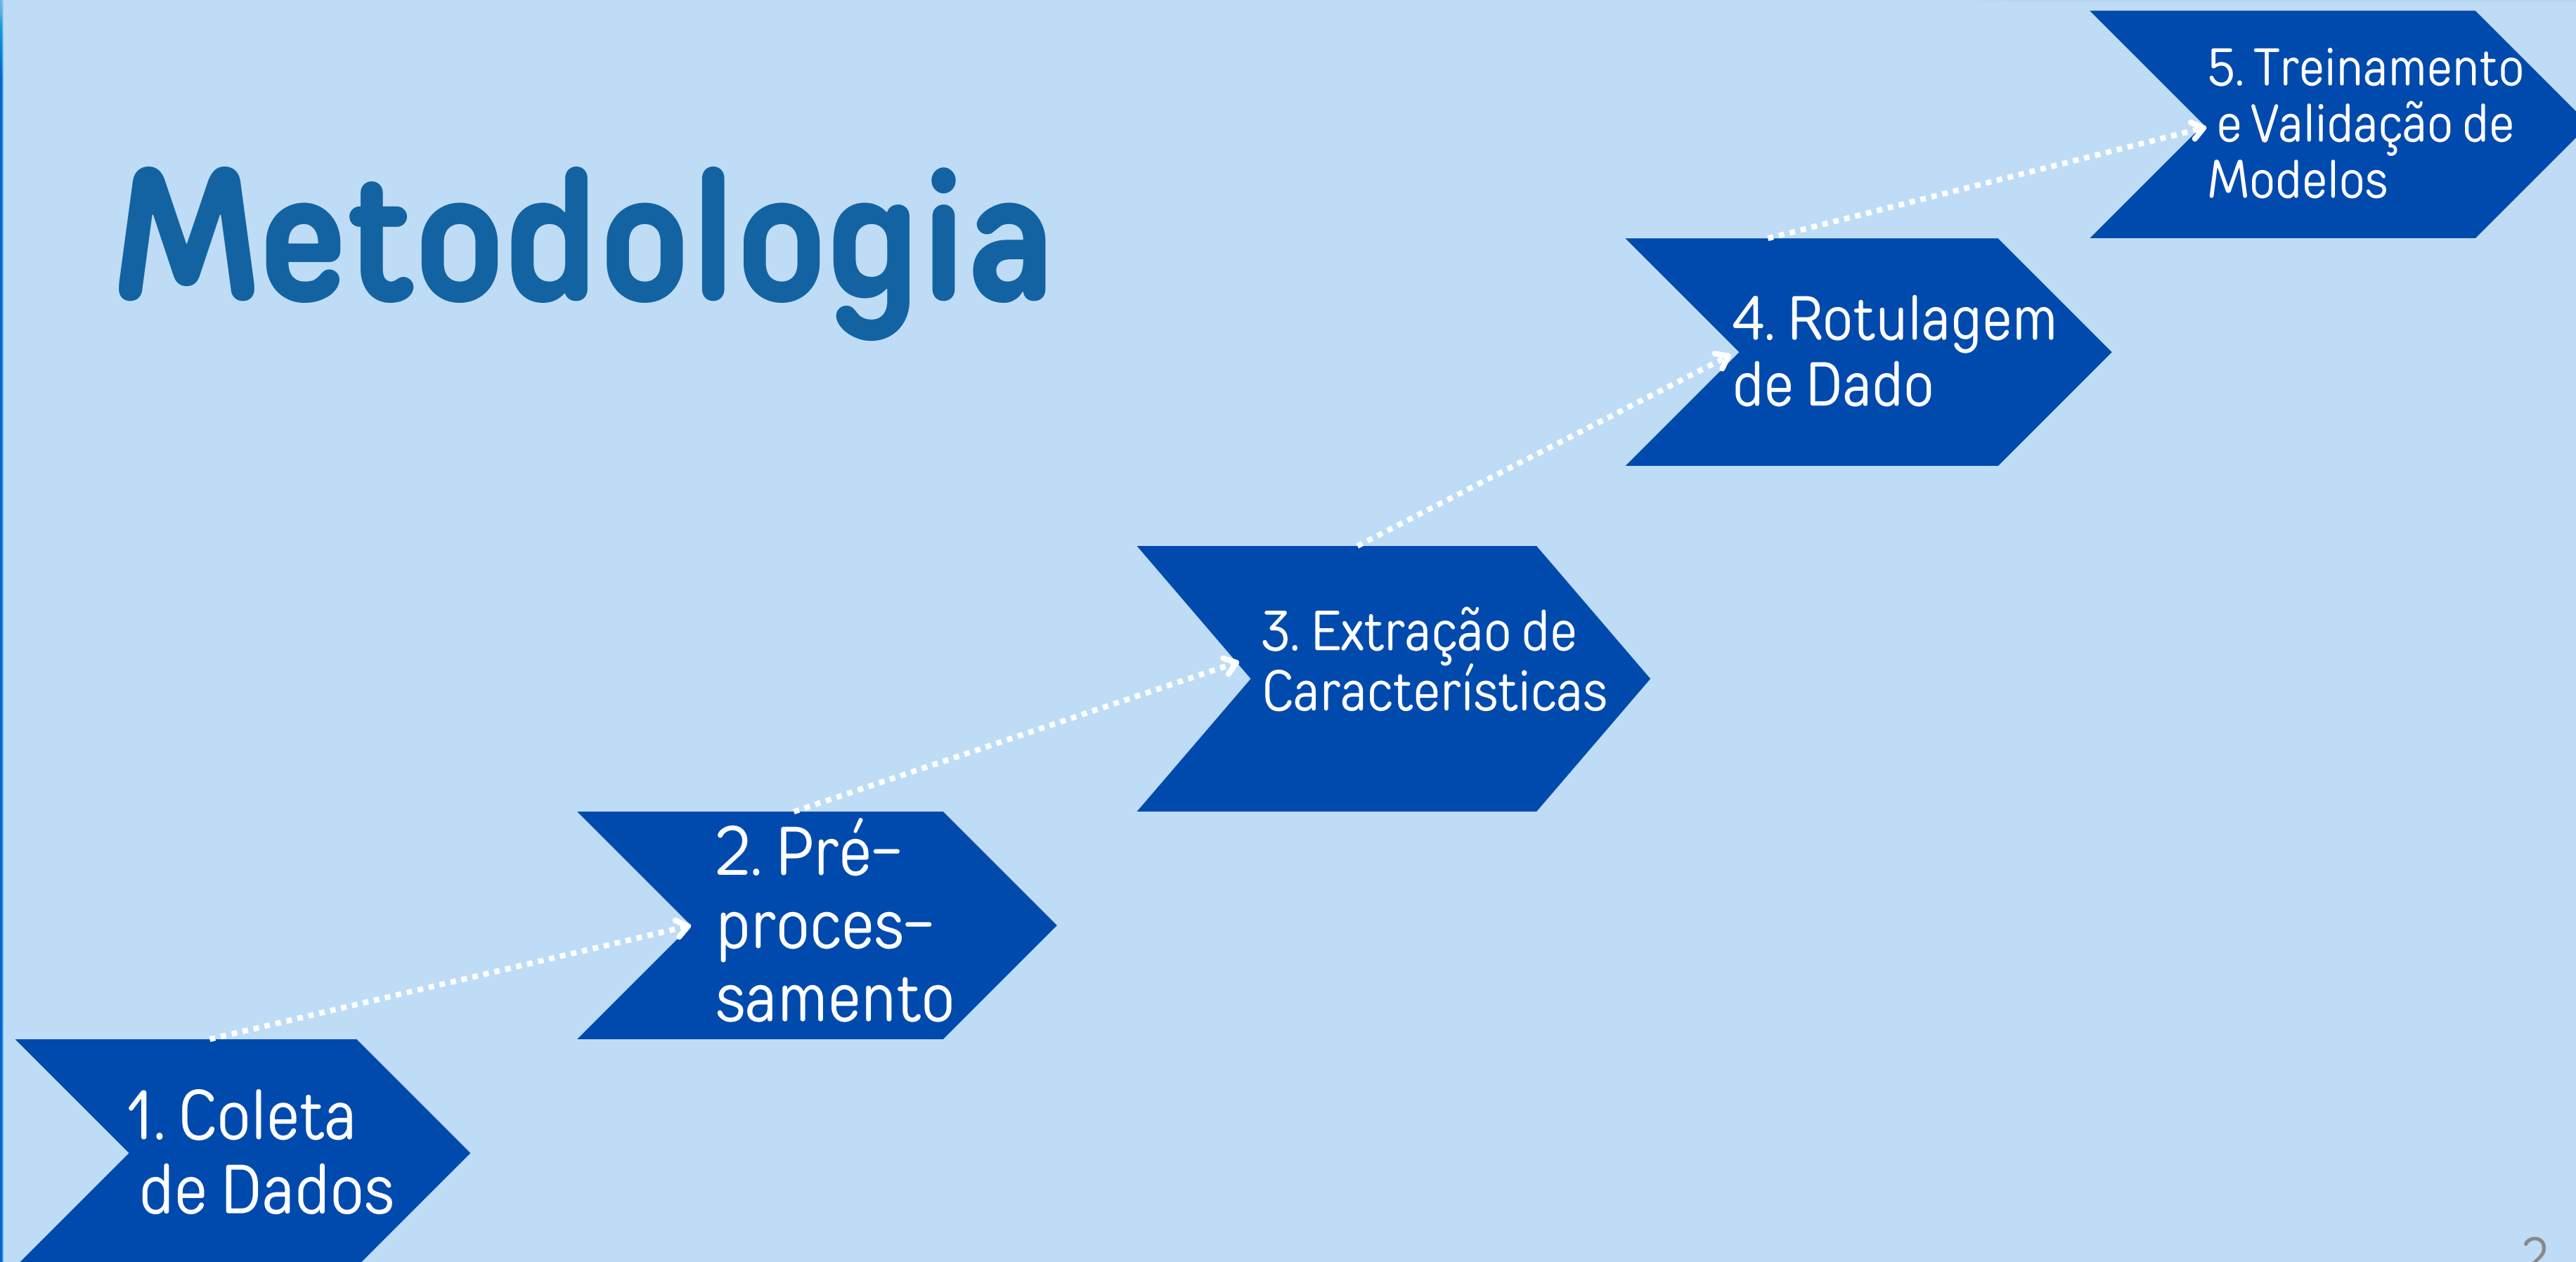
O artigo descreve uma solução inteligente de eficiência energética, para o gerenciamento de energia em edifícios, utilizando Internet das Coisas – **IoT** e Inteligência Artificial – **IA**. Dentro dessa abordagem, sensores coletam dados ambientais (como temperatura, umidade, CO₂) e dados sobre a ocupação dos ambientes. Esses dados são usados para prever e otimizar o consumo de energia.

- *Abordagem inteligente de gestão de energia com IoT e IA.*
- *Usa sensores IoT para monitoramento em tempo real de condições ambientais e consumo energético.*
- *Mostra como otimizar sistemas HVAC (Heating, Ventilation, and Air Conditioning), ou (Aquecimento, Ventilação e Ar Condicionado em português – sistemas responsáveis pelo controle de temperatura, umidade e qualidade do ar em ambientes internos), iluminação e outros dispositivos elétricos.*

Metodologia

- Experimentos realizados em um edifício de 3 andares com sensores IoT.
- Pré-processamento de dados coletados (filtragem, interpolação e normalização).
- Controle inteligente via BMS (Building Management System).
- Modelos de IA utilizados:
 - **LSTM** (Long Short-Term Memory) – Rede Neural capaz de aprender e manter informações mais relevantes por longos períodos. Foi utilizado para prever o consumo energético ao longo do tempo.
 - **CNN** (Convolutional Neural Network) – É uma classe de redes neurais profundas que é especialmente eficaz para tarefas de visão computacional. Ajudou a detectar padrões ou anomalias no uso d energia elétrica.
 - **DQN** (Deep Q-Network) – Rede neural utilizada em problemas de aprendizado por reforço. ajustar automaticamente o consumo de energia.

Metodologia



Resultados reproduzidos


- Gráfico 1: Previsão de Consumo Energético com LSTM.
- Gráfico 2: Redução de Consumo por Categoria (HVAC, Iluminação).
- Gráfico 3: Comparação do Consumo Diário Antes e Depois da Otimização.

Resultados reproduzidos

- Gráfico 1: Previsão de Consumo Energético com LSTM.
- Gráfico 2: Redução de Consumo por Categoria (HVAC, Iluminação).
- Gráfico 3: Comparação do Consumo Diário Antes e Depois da Otimização.

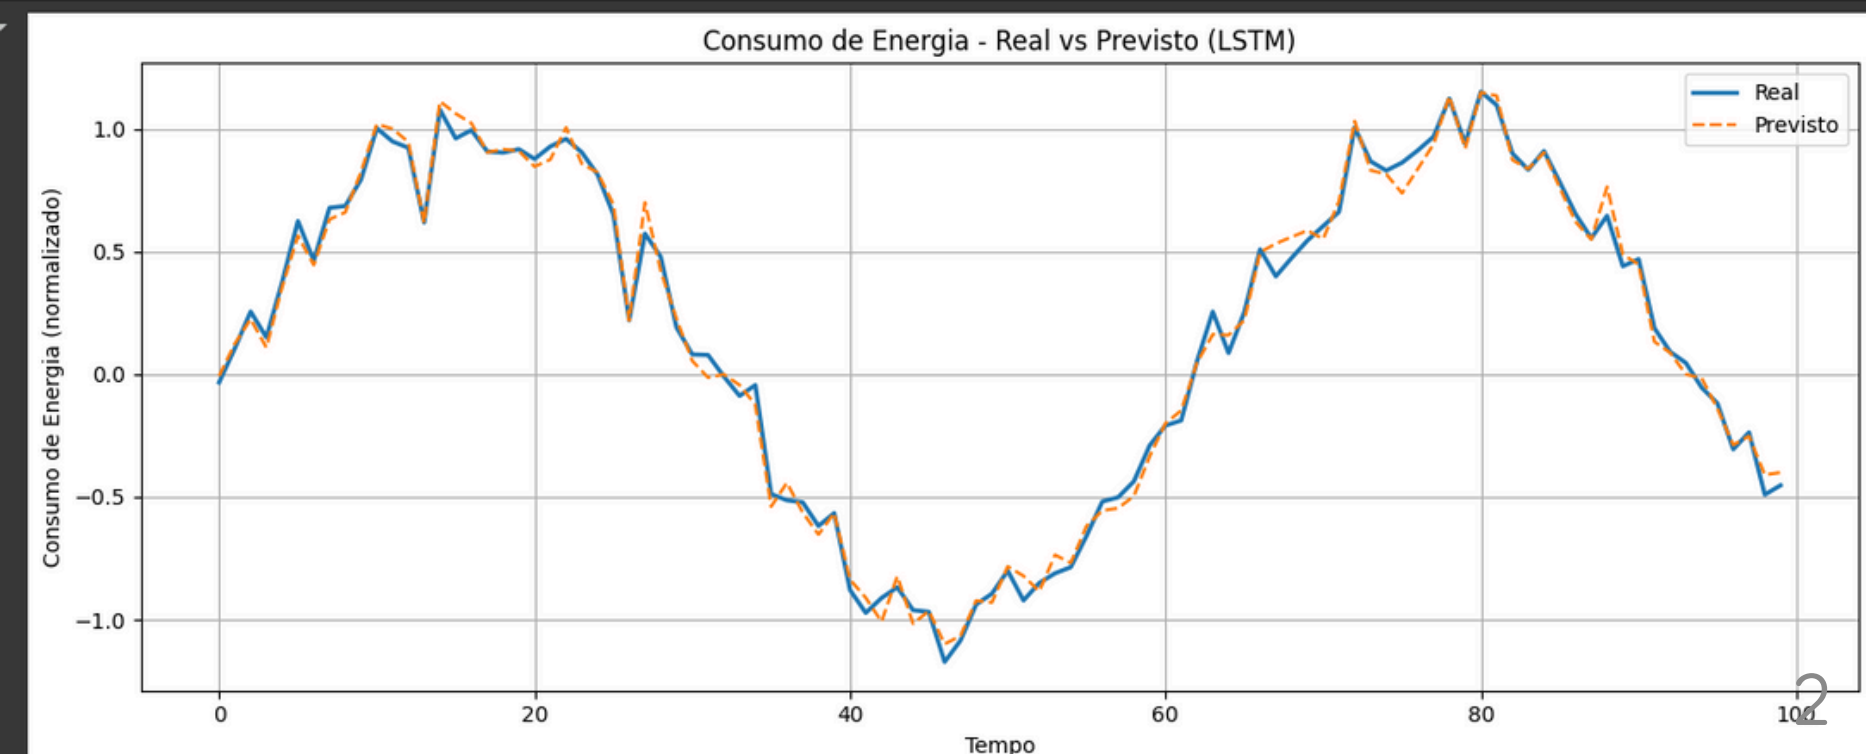
```
dias = list(range(1, 31))
consumo_antes = np.random.normal(loc=200, scale=10, size=30)
consumo_depois = consumo_antes * 0.75 # 25% de economia

plt.figure(figsize=(12, 5))
plt.plot(dias, consumo_antes, label="Antes (kWh)", color="red")
plt.plot(dias, consumo_depois, label="Depois (kWh)", color="green")
plt.title("Consumo Diário de Energia: Antes vs Depois da Otimização com IA")
plt.xlabel("Dias")
plt.ylabel("Consumo de Energia (kWh)")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```



```
# Simulação de dados
y = np.sin(np.linspace(0, 10, 100)) + 0.1 * np.random.randn(100) # real
preds = y + 0.05 * np.random.randn(100) # previsão

plt.figure(figsize=(12, 5))
plt.plot(y, label="Real", linewidth=2)
plt.plot(preds, label="Previsto", linestyle="--")
plt.xlabel("Tempo")
plt.ylabel("Consumo de Energia (normalizado)")
plt.title("Consumo de Energia - Real vs Previsto (LSTM)")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```




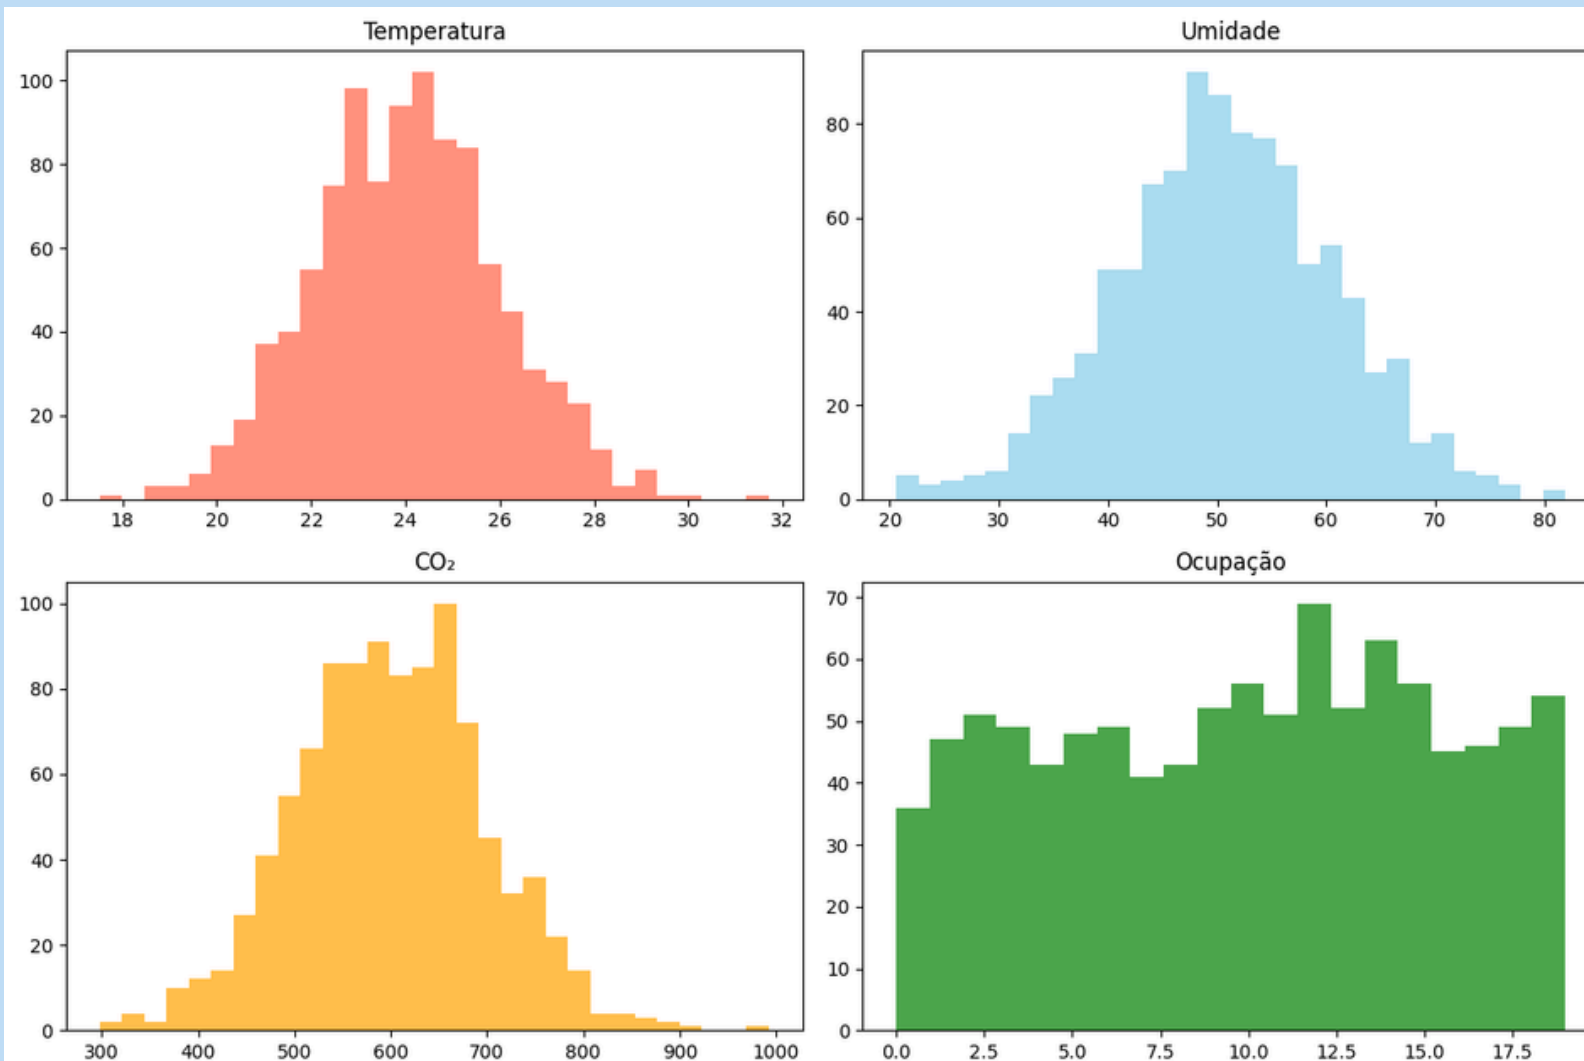
Simulação de Monte Carlo

Foi utilizada no estudo como uma ferramenta para avaliar a **incerteza e variabilidade** no comportamento do sistema de gestão de energia, levando em consideração as **flutuações nos dados** de entrada (como temperatura, CO₂, ocupação, etc.).

- Ajudou a entender como o consumo de energia varia com diferentes condições ambientais e de ocupação.
- Permitiu avaliar a **sensibilidade do sistema**, ou seja, como mudanças nas variáveis de entrada (como temperatura e CO₂) afetam o desempenho do sistema de gestão de energia.

É uma forma eficiente de prever e ajustar o comportamento do sistema em diferentes cenários, tornando-o mais robusto e eficiente em tempo real.

Simulação de Monte Carlo



• Geração das variáveis aleatórias

a) Definição das Variáveis: Quais variáveis terão suas incertezas modeladas. No caso do artigo, essas variáveis foram: **Temperatura (em °C)**, **Umidade (em %)**, **CO₂ (em ppm)**, **Ocupação (número de pessoas)**.

b) Escolha da Distribuição para Cada Variável: Para gerar as variáveis aleatórias, é necessário escolher uma distribuição estatística que represente o comportamento de cada uma dessas variáveis. No estudo, as distribuições escolhidas foram:

1- Temperatura: **(Distribuição Normal/)** ; 2- **CO₂** (Distribuição normal)

3- **Umidade** (Distribuição normal) ; 4- **Ocupação** : (Dist. Uniforme/ discreta)

Simulação de Monte Carlo

Simulação de Monte Carlo para Consumo de Energia

Este notebook utiliza variáveis aleatórias simuladas (temperatura, ocupação, CO₂, umidade) para prever o consumo de energia usando uma abordagem de Monte Carlo.

```
[ ] import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
```

Geração de Variáveis Aleatórias

```
[ ] np.random.seed(42)
n = 1000 # número de amostras

# Geração das variáveis
temperatura = np.random.normal(loc=24, scale=2, size=n) # graus Celsius
umidade = np.random.normal(loc=50, scale=10, size=n) # %
co2 = np.random.normal(loc=600, scale=100, size=n) # ppm
ocupacao = np.random.randint(0, 20, size=n) # número de pessoas

# Simulação do consumo energético (modelo fictício)
consumo = 50 + 1.2 * temperatura + 0.8 * ocupacao + 0.03 * co2 - 0.5 * umidade
consumo += np.random.normal(0, 5, size=n) # ruído

df = pd.DataFrame({
    "Temperatura": temperatura,
    "Umidade": umidade,
    "CO2": co2,
    "Ocupação": ocupacao,
    "Consumo (kWh)": consumo
})

df.head()
```

| | Temperatura | Umidade | CO2 | Ocupação | Consumo (kWh) |
|------|-------------|-----------|------------|----------|---------------|
| 0 | 24.993428 | 63.993554 | 532.482173 | 8 | 76.558424 |
| 1 | 23.723471 | 59.246337 | 585.548133 | 6 | 78.105950 |
| 2 | 25.295377 | 50.596304 | 520.758008 | 14 | 80.543409 |
| 3 | 27.046060 | 43.530632 | 569.203847 | 1 | 80.881747 |
| 1074 | 23.531693 | 56.982233 | 410.638533 | 19 | 75.468627 |

Estatísticas do Consumo

```
df["Consumo (kWh)"].describe()
```

| | Consumo (kWh) |
|-------|---------------|
| count | 1000.000000 |
| mean | 79.454895 |
| std | 9.115236 |
| min | 51.828593 |
| 25% | 73.282683 |
| 50% | 78.967679 |
| 75% | 85.658562 |
| max | 107.474842 |

dtype: float64

• Conclusão

- Soluções IoT e IA são promissoras para otimização de consumo energético.
- Resultados: redução de até 33.8% no consumo energético.
- Simulação de Monte Carlo ajudou a entender a sensibilidade do sistema.

Referência

BUDZIANOWSKI, Wojciech M.; KWASNIK, Marcin; WRONA, Paulina.

- “*Internet of Things Applications for Energy Management in Buildings Using Artificial Intelligence*”—A Case Study. *Energies*, Basel, v. 18, n. 7, p. 1706, 2025.
- Disponível em: <https://doi.org/10.3390/en18071706>.

- Todos os códigos utilizados estão disponíveis no GitHub:

danielquiteque/TP547-Trabalho-Final-1: O presente repositório faz parte da disciplina de TP547- Da Disciplina de Princípios de Simulação, onde são apresentados os resultados do trabalho final parcial 01

- Link da simulação: [TP547-TF1_simulacao_monte_carlo_energia.ipynb](#) – Colab

Relatório resumido do artigo: "Internet of Things Applications for Energy Management in Buildings Using Artificial Intelligence" – A Case Study

Autores :W. M. Budzianowski, M. Kwasnik, and P. Wrona,

Estudante: **Daniel Quiteque**

Professor: **Prof. Doutor Samuel Beraldi Mafra**

05 de Maio de 2025



TRABALHO FINAL 1 – TP547 – PRINCÍPIOS DE SIMULAÇÃO